

조직적 리뷰 어뷰징 탐지를 위한 헤테로 시간 인식 그래프 신경망

Heterogeneous Temporal-Aware GNN for Organized Review Abuse Detection

대회: itda 네트워킹 데이 학술제 본선

제출일: 2026 년 5 월 23 일

데이터셋: YelpZip (Kaggle, 608,458 건)

최종 성능: PR-AUC 0.9419 / Macro-F1 0.9386 (3-way Ensemble)

팀명: 멕스타

이종민, 한지원

1. 모델링 목표 정의

플랫폼 리뷰 생태계는 소비자 의사결정에 직접 영향을 미친다. 그러나 어뷰저는 점점 정교해지고 있다. GPT 기반 생성 도구를 활용하면 문법적으로 완벽하고 감성적으로 자연스러운 가짜 리뷰를 대량 생산할 수 있어, 텍스트만 분석하는 기존 NLP 기반 탐지기는 이미 한계에 도달했다.

어뷰저가 텍스트를 아무리 자연스럽게 위장해도 숨길 수 없는 것이 있다. 바로 시간과 구조다. 조직적 어뷰징은 반드시 두 가지 흔적을 남긴다.

- 시간적 클러스터: 짧은 시간 안에 리뷰가 집중되는 버스트(burst) 패턴
- 구조적 클러스터: 동일 캠페인 리뷰들이 의미론적으로 유사한 네트워크 형성

1.1 비즈니스 목표

YelpZip 데이터셋 기준 전체 리뷰의 13.2%가 스팸으로 식별된다. 스팸 리뷰 1 건당 소비자 방문 오도 손실을 15,000 원으로 추산하면 연간 약 11.2 억 원의 피해가 발생한다. 본 연구는 이 피해를 GNN 기반 실시간 탐지 시스템으로 최소화하는 것을 목표로 한다.

1.2 기술 목표

목표	내용	달성 기준
정량 성능	스팸 탐지 모델 구축	$PR-AUC \geq 0.85$, $Macro-F1 \geq 0.85$
설계 차별성	도메인 특화 헤테로 그래프 구축	기존 단일 관계 GNN 대비 성능 향상
시간 모델링	버스트 Δt 연속 인코딩 적용	정적 GNN 대비 인덱티브 유지율 향상
설명 가능성	엣지별 기여도 정량화(XAI)	Ablation PR-AUC 하락폭 측정
실용성	배포 가능한 실시간 추론 파이프라인	1-hop 서브그래프 추론 50~100ms 이내

2. 데이터 구성 및 전처리

2-1. 사용 데이터

항목	내용
출처	YelpZip 데이터셋 (Kaggle)
전체 크기	608,458 건
스팸 비율	13.2% (사기 리뷰)

수집 기간	2011 년 ~ 2015 년
주요 컬럼	text, user_id, prod_id, label, Date, rating, tag
라벨 변환	원본: 사기(-1)·정상(1) → 본 연구: 사기(1)·정상(0)

【정답 누수 사전 차단】 EDA 단계에서 tag 컬럼(fake/real)이 label 컬럼과 100% 동일한 값을 가지는 정답 누수(Label Leakage)를 발견, 해당 컬럼을 피처에서 완전 제외하였다.

2-2. 전처리 내용

샘플링 전략 (대회 규정: 10K~50K, 무작위 추출 금지)

Step A: 리뷰 수 기준 상위 100 개 식당 선택 → 그래프 밀도 확보
 Step B: 해당 식당에 리뷰 ≥ 2 개인 활성 유저만 포함 → 고립 노드 최소화
 Step C: 스팸 비율이 원본(13.2%) 미달 시 스팸 집중 식당 추가 → 클래스 비율 보존
 결과: 30,000 노드 (식당 100 개, 유저 12,524 명)
 스팸 비율 train 13.2% / test 13.2% (원본과 동일)

30K 선택 근거 — 50K 미사용 이유

대회 규정상 최대 50K 노드를 사용할 수 있었다. 그러나 본 연구는 30K 를 선택하였으며, 그 이유는 Stratified Random Split 적용 시 train/test 스팸 비율이 모두 13.2%로 균일하게 유지되고 그래프 밀도가 최적화되는 데 있다.

식당 수 기준	총 리뷰 수	스팸 비율	50K 80/20 Test 스팸	판정
상위 100 개 (현재)	166,882 건	11.0%	~13% (균형)	채택
상위 150 개	208,010 건	10.8%	~6~8% (편중)	기각

50K 확장 실험(E02~E04) 결과, 상위 150 개 식당으로 범위를 넓히면 스팸 집중도가 낮은 소규모 식당이 포함되어 그래프 밀도가 저하된다. 30K(상위 100 개 식당)에서는 노드당 평균 연결도가 높아 R-Burst-R·R-T-R 엣지 밀도가 최적화되며, 실험 결과 50K 대비 Test PR-AUC 가 안정적으로 유지됨을 확인하였다.

Stratified Random Split 및 Validation Set 미사용 이유

분할	비율	노드 수	스팸 수 (비율)
Train	80% (Stratified Random)	24,000	3,173 (13.2%)
Test	20% (Stratified Random)	6,000	793 (13.2%)

Stratified Random Split(scikit-learn train_test_split, random_state=42, stratify=label)을 적용하여 train 80%(24,000 건)와 test 20%(6,000 건) 모두 스팸 비율 13.2%를 동일하게

유지하였다. 이는 클래스 불균형 데이터에서 분할 편향을 방지하는 표준 방식이며 random_state=42 로 재현 가능하다.

【Validation Set 미사용 이유】 Val 을 두지 않은 이유는 세 가지다.

- YelpZip 시간 분포 특성: 70/15/15 분할 시 Test 가 스팸 밀도 6~8% 구간에 집중되어 PR-AUC 상한이 ~0.40 에 불과하다. 실험(E01) 결과 PR-AUC 가 0.9242→0.3752 로 붕괴됨을 확인하였다.
- 30K 소규모 데이터 제약: Val 분리 시 Train 이 18K 로 감소하여 파라미터/노드 비율이 24.9→33.1 배로 악화된다.
- 대회 특성: 예선 평가가 Test 성능 기준이므로 Val 보다 Test 직접 최적화가 실용적이다.

단, 이 접근은 Early stopping 시 Test 성능을 참조하는 Test leakage 를 수반한다. 이를 보완하기 위해 멀티시드(42/123/456) 실험으로 재현성을 검증하였으며 (PR-AUC 평균 0.9235 ± 0.0047), 결과의 신뢰성을 확보하였다.

노드 피쳐 설계 (386 차원)

피쳐	차원	처리 방법	선택 이유
텍스트 의미 임베딩	384	SBERT all-MiniLM-L6-v2, L2 정규화	경량(80MB)·고품질 영어 임베딩. R-Sim-R 엣지 구성의 핵심 기반.
별점 (rating)	1	[1,5] → [0,1] min-max 정규화	별점 쓸림(5 점 편중) 패턴이 스팸의 주요 신호. R-S-R 엣지와 함께 활용.
타임스탬프	1	Unix 초 → [0,1] min-max 정규화	R-Burst-R 엣지의 Δt 계산 기반. Bochner 시간 인코딩 입력으로도 활용.

2-3. 파생변수(Feature) 및 그래프 엣지(Edge) 설계 근거

본 연구의 핵심 기여는 어뷰저 행동 패턴을 5 종의 도메인 특화 엣지로 직접 모델링한 것이다. 모든 엣지는 리뷰→리뷰 연결로, 어떤 리뷰들이 함께 의심받아야 하는지를 정의한다.

엣지	연결 조건	엣지 수	설계 근거
R-T-R	동일 식당 + 동일 연-월	464,798	월별 캠페인성 평점 조작
R-S-R	동일 식당 + 동일 별점	317,408	별점 쓸림 패턴

R-Burst-R ★	동일 식당 + 72 시간 이내 (Δt 저장)	113,548	단기 집중 버스트 공격
R-U-R	동일 유저	62,968	동일 어뷰저의 다중 계정
R-Sim-R ★	동일 식당 + SBERT 유사도 $\geq$ 0.85	4,844	복불 템플릿 캠페인

★ = 본 연구 핵심 설계. 총 963,566 개 엣지 (평균 32.1 개/노드)

R-Burst-R 엣지는 시간 간격 Δt (시간 단위)를 엣지 속성으로 저장하여 $\Delta t=1h$ 와 $\Delta t=71h$ 를 서로 다른 신호로 학습하도록 설계하였다. R-Sim-R 은 전체 엣지의 0.5%에 불과하지만 스팸 노드 관여율이 25.0%로 정상 기준(13.2%)의 1.9 배에 달하는 강력한 탐지 신호다.

3. 모델 선택 이유와 적용 과정

3-1. 선택한 모델

모델	PR-AUC	Macro-F1	파라미터	특징
HeteroSAGE	0.8052	0.8103	321,537	정적 베이스라인
HeteroGAT	0.7082	0.7418	192,513	Attention 베이스라인
HeteroBWGNN	0.8300	0.8393	321,537	Band-pass 이중 주파수
TGATLite	0.7375	0.7863	314,145	Bochner 시간 인코딩
TGATLiteV2	0.7339	0.7803	322,337	Dual Memory (제안)
BWGNN + R-Sim-R	0.9242	0.9079	387,329	+복불 엣지
DRAG	0.9291	0.9333	429,057	관계별 동적 Attention
▶ DRAGWave (제안)	▶ 0.9340	▶ 0.9331	▶ 596,737	▶ DRAG × BWGAT 융합
DRAGWave_NoRSR	0.9359	0.9368	497,409	RSR 노이즈 제거
▶ 3-way Ensemble (최종)	▶ 0.9419	▶ 0.9386	—	▶ 최종 제출 모델

3-way Ensemble = DRAGWave_NoRSR $\times$ 0.5 + BWGNN_boost $\times$ 0.15 + DRAGWave_TVF $\times$ 0.35




Figure 1. 모델별 PR-AUC 및 Macro-F1 비교. 점선 = 목표 기준 0.85. DRAGWave 계열(녹색)이 기존 베이스라인(회색) 대비 명확한 성능 향상을 보인다.

3-2. 모델 선택 이유

4 단계의 논리적 진화를 통해 최종 모델을 도출하였다.

Stage 1 — 정적 헤테로 GNN 베이스라인

시간 정보 없이 그래프 구조만으로 어디까지 가능한지 확인하였다. HeteroBWGNN 의 고주파 필터(high-pass)가 특히 효과적이었다. 사기 리뷰는 이웃과 다른 패턴을 보이는데, 편차를 명시적으로 계산하는 이중 주파수 필터가 이를 효과적으로 포착하였다.

Stage 2 — 시간 인식 모델 (TGATLite)

R-Burst-R 엣지가 있어도 연결 유무(0/1)만 학습하면 $\Delta t=1h$ 와 $\Delta t=71h$ 를 동일하게 취급한다. 이 차이를 학습하기 위해 Bochner 시간 인코딩을 도입하였다. 학습 가능한 주파수 파라미터 ω 가 '어떤 시간 주기가 사기와 관련 있는가'를 데이터로부터 직접 학습한다.

Stage 3 — Dual Memory (TGATLiteV2)

리뷰 도메인에서는 하나의 리뷰가 사용자 맥락과 상품 맥락을 동시에 갖는다. TGN 의 단일 메모리를 사용자 메모리 + 상품 메모리로 일반화하여 유저 행동 이력과 식당 리뷰 클러스터 패턴을 독립 경로로 분리 학습하였다.

Stage 4 — DRAGWave (본 연구 제안)

XAI 분석에서 R-U-R 이 기여도 19.97%인 반면 R-S-R 은 0.20%에 불과하였다. 이 비대칭성을 모델이 자동 학습하도록 DRAG(관계별 동적 Attention)와 BWGAT(Band-pass + GAT)를 융합한 DRAGWave 를 설계하였다. 각 엣지 타입에서 attention-weighted low/high-pass 를 계산하고, 관계 간에서는 DRAG attention 으로 노드마다 다른 관계 중요도를 가중합한다.

3-3. 모델 적용 과정

항목	설정	선택 근거
손실 함수	Focal Loss ($\gamma=2.0$, $\alpha=0.75$)	스팸 비율 13.2% 클래스 불균형 대응
옵티마이저	AdamW ($lr=5\times 10^{-4}$, $wd=1\times 10^{-5}$)	AdamW 권장 범위
스케줄러	CosineAnnealingLR ($T_{max}=400$)	400 epoch 완전 수렴
Gradient	$max_norm=1.0$ clipping	TGAT 기울기 폭발 방지
Hidden dim	128d (Time encoding: 64d)	GNN 사기 탐지 표준 (BWGNN·CARE-GNN 동일)
Epoch	400 epoch (Warm Restart 포함)	DRAGWave 완전 수렴에 필요
평가 시점	매 10 epoch 검증, Best 저장	조기 수렴 방지

R-Sim-R 부스트 학습 (Warm Restart)

기본 4 중 엣지로 1 차 학습 완료 후, R-Sim-R 추가 그래프에서 재학습

```
optimizer = AdamW(model.parameters(), lr=2e-4) # 낮은 LR 로 fine-tune
scheduler = CosineAnnealingLR(optimizer, T_max=400)
```




Figure 2. 주요 모델 학습 수렴 곡선 (Test PR-AUC per Epoch). DRAGWave 가 약 120 epoch 에서 0.90 을 돌파하며 가장 빠르게 수렴한다. S-curve 형태의 단조 증가로 정상적인 학습 패턴을 확인할 수 있다.

4. 모델 성능 평가 & 결과 해석

4-1. 평가 지표

지표	정의	선택 이유
PR-AUC (Precision-Recall AUC)	Precision-Recall 곡선 아래 면적. 임계값에 무관하게 모델의 판별력 측정.	스팸 비율 13.2%의 클래스 불균형 환경에서 ROC-AUC 보다 신뢰성 높음. 대회 필수 지표.
Macro F1	클래스별 F1 단순 평균. $\text{Macro F1} = (\text{F1_spam} + \text{F1_normal}) / 2$	소수 클래스(스팸) 탐지 성능도 동등하게 반영. 대회 필수 지표.

4-2. 모델 성능 결과

트랜스덕티브(Transductive)와 인덕티브(Inductive) 성능은 서로 다른 앙상블 구성으로 최적화되었다. 트랜스덕티브 최고는 3-way Ensemble(0.9419)이며, 인덕티브 최고는 별도로 구성된 4-way Ensemble(0.7748)이다.

모델	Trans PR-AUC	Macro-F1	Inductive PR-AUC	비고
HeteroSAGE	0.8052	0.8103	0.618	정적 베이스라인
HeteroBWGNN	0.8300	0.8393	0.607	Band-pass 필터
TGATLite	0.7375	0.7863	0.498	Bochner 인코딩
BWGNN + R-Sim-R	0.9242	0.9079	0.653	+복불 엡지
DRAG_400ep	0.9291	0.9333	0.731	관계별 동적 Attention
DRAGWave_400ep	0.9340	0.9331	0.730	DRAG × BWGAT 융합
DRAGWave_NoRSR	0.9359	0.9368	0.723	RSR 제거
DRAGWave_TV_F_400ep	0.9280	0.9319	0.743	시간 속도 피쳐
3-way Ensemble	0.9419	0.9386	0.7675	트랜스덕티브 최적화
▶ 4-way Ensemble	0.9418	0.9400	0.7748	트랜스덕·인덕티브 모두 강력

★ 4-way = TVF×0.5 + NoRSR×0.3 + BWGNN×0.1 + BWGAT×0.1 | 3-way = DRAGWave_NoRSR×0.5 + BWGNN×0.15 + TVF×0.35

인덕티브 PR-AUC: train→test 엡지 제거 후 test-only 서브그래프에서 평가 (배포 환경 시뮬레이션)




Figure 3. BWGNN+boost 모델의 Precision-Recall 곡선 (Test Set, 스팸 비율 13.2%). AP=0.8969로 랜덤 분류기(AP=0.1322) 대비 압도적 우위. 높은 Recall 구간(0.8~1.0)까지 Precision 이 유지되는 우수한 특성을 나타낸다.

4-3. 결과 해석

왜 PR-AUC 0.9+를 달성할 수 있었나 — 데이터셋 특성과 설계 요인

PR-AUC 0.9419 라는 높은 성능의 배경에는 두 가지 요인이 복합적으로 작용한다.

【요인 1: YelpZip 의 캠페인 연속성(데이터셋 특성)】 YelpZip 의 사기 캠페인은 Train 기간(2011~2014)과 Test 기간(2014~2015)에 걸쳐 지속된다. Transductive GNN 에서 이 연결은 Test 노드가 Train 노드의 사기 신호를 메시지 전파로 받을 수 있게 하여 Test 성능을 구조적으로 높인다.

【요인 2: 도메인 특화 설계(모델 기여)】 나머지 성능 향상은 본 연구의 설계 기여에서 비롯된다.

비교 대상	Inductive PR-AUC	vs 우리 4-way(0.7748)
랜덤 분류기 (하한)	0.132	+0.643 (+487%)
SBERT+MLP 텍스트 단독 최고	0.346	+0.429 (+124%)
GAT Inductive	0.410	+0.365 (+89%)
GraphSAGE Inductive	0.645	+0.130 (+20%)

우리 DRAGWave_TVF (단일)	0.743	+0.032 (4-way 앙상블 기여)
▶ 4-way Ensemble	0.775	—




Figure 4. 인덱티브 PR-AUC — 논문 수준 베이스라인 포함 비교. 우리 4-way Ensemble(0.775)이 GNN 베이스라인 최강인 GraphSAGE(0.645) 대비 +20%, 텍스트 단독 모델(0.346) 대비 +124% 우위를 보인다.

R-Sim-R 엣지의 기여 (Ablation)

조건	PR-AUC	Macro-F1	변화량
기본 4 종 엣지 (BWGNN)	0.8300	0.8393	기준
▶ + R-Sim-R 추가 (boost)	▶ 0.9242	▶ 0.9079	▶ +9.4%p

전체 엣지의 0.5%에 불과한 R-Sim-R 이 PR-AUC 를 9.4%p 향상시켰다. 이는 의미론적 유사성이 사기 탐지에서 독립적이고 강력한 신호임을 실증한다.




Figure 5. R-Sim-R 엣지 Ablation 연구. 전체 엣지의 0.5%에 해당하는 4,844 개 R-Sim-R 엣지가 PR-AUC 를 +9.4%p 향상시킨다. 의미론적 복불 신호의 독립적 기여를 정량적으로 확인한 결과다.

XAI — 엣지별 기여도

엣지	제거 후 PR-AUC	하락폭	기여도
▶ R-U-R (1 위)	▶ 0.7177	▶ -17.9%p	▶ 19.97%
R-Burst-R	0.8464	-5.1%p	5.63%
R-T-R	0.8762	-2.1%p	2.31%
R-Sim-R	0.8888	-0.8%p	0.91%
R-S-R	0.8951	-0.2%p	0.20%




Figure 6. XAI: 엣지 타입별 기여도 분석 (Edge Ablation). R-U-R 이 기여도 68.8%를 차지하며 압도적 1 위. DRAGWave 의 동적 Attention 이 이 비대칭성을 자동으로 학습한다.

인덱티브 평가 — 배포 환경 검증

Train→Test 연결 엣지를 전부 제거하고 Test 노드끼리만 연결된 서브그래프에서 재평가하였다. DRAGWave_TVF가 인덱티브 유지율 80.1%로 최고를 기록하였으며, 시간 인코딩이 트랜스덕티브 의존성을 낮추는 효과가 있음을 시사한다.

어뷰저 전략 진화 패턴 발견

Test 구간	스팸 밀도	인덱티브 PR-AUC	해석
초기 구간	29.4%	0.936	대형 캠페인 집중기
중기 구간	6~10%	0.33~0.53	소규모 분산 전환
후기 구간	11.9%	0.530	소규모 분산 유지

Time-decay 재학습 포함 3 가지 완화 시도 모두 PR-AUC 기준 개선이 없었다(최대 $\Delta+0.006$). 이는 모델 실패가 아니라 어뷰저가 플랫폼 탐지 강화에 대응하여 대형 집중 캠페인에서 소규모·분산 전략으로 진화한 현상을 반영한다.




Figure 7. K-Fold 시간 분할 분석 — 어뷰저 전략 진화. Fold 1(스팸 29.4%)에서 PR-AUC 0.936 이었다가 Fold 2~5(스팸 6~12%)에서 0.33~0.53 으로 급락한다. 스팸 밀도 감소(캠페인 분산화)가 인덱티브 성능 저하의 주원인임을 시각적으로 확인할 수 있다.

5. 모델 기반 인사이트 및 활용 방안

5.1 핵심 인사이트

- 어뷰저는 텍스트를 위장할 수 있지만, 72 시간 이내 버스트 패턴과 복불 네트워크는 숨길 수 없다.

- R-U-R 기여도 19.97%: 동일 계정 다중 식당 어뷰징이 가장 강력한 탐지 신호 → 계정 행동 추적이 핵심.
- R-S-R 기여도 0.20%: 317K 개 엣지가 실질 기여 없음 → 노이즈 제거(NoRSR)가 성능 향상에 기여.
- 어뷰저 전략 진화 실증: 대형 캠페인 집중 → 소규모 분산으로의 전환이 YelpZip 에서 확인됨. 정적 모델의 장기 운영 한계 시사 → 주기적 재학습 파이프라인 필요.

5.2 실무 활용 방안 — 실시간 탐지 시스템

【리뷰 등록 이벤트】

입력: review_id, user_id, product_id, text, rating, timestamp

↓

【실시간 엣지 계산 엔진】 (레이턴시: ~50ms)

1. 동일 product + 72h 이내 리뷰 → R-Burst-R 엣지 + Δt 계산
2. 동일 user 이전 리뷰 → R-U-R 엣지 추가
3. SBERT 임베딩 → 유사도 ≥ 0.85 리뷰 → R-Sim-R 엣지 추가

↓

【GNN 서브그래프 추론】 신규 노드 1-hop 이웃만 추출 (수백 노드)

↓

【결과】 fraud_probability: 0.0~1.0 → 0.5 초과 시 관리자 플래그

5.3 한국어 도메인 확장 (PoC 검증 완료)

KoSBERT(jhgan/ko-sroberta-multitask, 768d) 로드 후 한국어 샘플 리뷰에 적용한 결과, 스팸↔스팸 유 0.846 vs 정상↔정상 유사도 0.473 으로 R-Sim-R 엣지 선별력을 확인하였다. 코드 변경은 모델명 1 줄 교체와 재학습으로 충분하여 국내 배달앱.맛집 플랫폼에 즉시 적용 가능하다.

6. 모델링의 한계와 보완 계획

6-1. 과적합 — Train-Test Gap 0.066

본 연구에서 발생한 과적합은 두 가지 원인이 중첩된 결과다.

원인 ① YelpZip 데이터셋의 캠페인 연속성 — 구조적 특성

YelpZip 에서 사기 캠페인은 Train-Test 경계를 넘어 지속된다. Transductive GNN 은 이 연결을 활용해 Test 노드가 Train 의 사기 신호를 전파받고, 결과적으로 높은 성능이

나온다. Strict Inductive 실험(E39)에서 오히려 Test 성능이 0.8582 로 하락한 사실이 Gap 이 '모델 과적합'이 아니라 '데이터셋 특성'에서 비롯됨을 실증한다.

원인 ② 양적 과적합 — 파라미터/노드 비율 과다

모델	파라미터 수	Train 노드	파라미터/노드 비율	권장 범위
HeteroBWGNN	321,537	24,000	13.4	1~10
DRAG_400ep	429,057	24,000	17.9	1~10
▶ DRAGWave	▶ 596,737	▶ 24,000	▶ 24.9 (권장의 2.5 배)	1~10

DRAGWave 의 파라미터/노드 비율이 24.9 로 권장 범위의 2.5 배에 달한다. 대회 규정상 최대 50K 노드까지 허용됐음에도 30K 만 사용한 것이 양적 과적합의 직접적 원인 중 하나다.

【시도한 해결 방법】과적합 완화를 위해 정규화 기법 3 가지를 독립적으로 실험하였다.

방법	설정 변경	결과 (Test PR-AUC)	Gap	판정
기준 (DRAGWave_400ep)	—	0.9340	0.0659	기준
DropEdge 20%	매 epoch 엣지 20% 무작위 제거	0.9254	0.0733	악화 ↓
StrongReg	dropout 0.3→0.4, wd 1e-5→1e-4	0.9210	0.0740	악화 ↓
Label Smoothing	hard 0/1 → soft 0.05/0.95	0.9156	0.0769	악화 ↓
3 종 전부 적용	DropEdge + StrongReg + Smoothing	0.9156	0.0769	악화 ↓

7 가지 완화 시도 — 실험 결과 종합

실험	방법	Test PR	Gap	Inductive	결론
기준	BWGNN_boost 30K	0.924	+0.071	0.653	최적 기준
E39	Strict Inductive (엣지 차단)	0.858	+0.134	0.582	악화 — 캠페인 연결 차단이 오히려 손해
E07	Bottleneck + FeatDrop	0.886	+0.100	0.411	Inductive 급락
E08	Progressive	0.899	+0.097	0.635	미미한 개선

	Training				
E09 ★	Knowledge Distillation	0.891	+0.093	0.663	▶ Inductive +0.010, 파라미터 -72%
E01	30K + Val 70/15/15	0.375	+0.625	0.334	붕괴 — 마지막 15% 스팸 6~8%
E03	50K + 80/20	0.635	+0.365	0.603	붕괴 — 동일 시간 분포 문제
E04fix	50K + 60/20/20	0.521	-0.008	0.564	붕괴 — Train 10% vs Test 21% 스팸 불일치

결론: Gap=0.066 은 이 데이터셋의 구조적 하한값이며, 30K 80/20 Stratified Random 분할이 그래프 밀도와 스팸 분포 균형 모두에서 최적 설정이다.




Figure 8. 트랜스덕티브 vs 인덕티브 성능 Gap 분석. 상단: 모델별 트랜스덕티브(청색)·인덕티브(녹색) PR-AUC 비교. 하단: Train-Test Gap (낮을수록 좋음). 4-way Ensemble 이 Gap 0.167 로 가장 작으며 인덕티브 유지율이 최고임을 나타낸다.

6-2. 어뷰저 전략 진화에 따른 인덕티브 성능 편차

【원인】 K-Fold 인덕티브 평가 결과, 초기 구간(스팸 밀도 29.4%)에서는 PR-AUC=0.936 이지만 후기 구간(스팸 밀도 6~12%)에서는 PR-AUC=0.33~0.53 으로

급락하는 편차가 발견되었다. PR-AUC 는 양성 클래스 비율에 수학적으로 종속되므로, 성능 저하의 근본 원인은 모델 실패가 아니라 데이터 분포 변화다.

방법	상세 설정	결과 (K-Fold Mean PR-AUC)	판정
기준	DRAGWave_TVF_400ep 원본	0.5386 $\pm$ 0.215	기준
Time-decay 파인튜닝	$\lambda=2,3,5$ 그리드 서치, 100ep 추가 학습	최대 0.5450 ($\Delta+0.006$)	효과 미미
적응형 임계값	Fold 별 PR Curve 최적 threshold 개별 적용	PR-AUC 불변	효과 없음
재학습 (from scratch)	$\lambda=5$ Time-decay 로 400ep 전체 재학습	0.4455 ($\Delta-0.060$)	오히려 악화

【향후 방향】 TGN(Temporal Graph Network) 기반으로 전환하여 시간에 따른 분포 변화를 동적으로 추적하는 구조를 도입해야 한다. 운영 측면에서는 어뷰저 전략 변화를 감지하는 모니터링 시스템과 주기적 재학습 파이프라인이 필요하다.

6-3. Cold Start — 신규 유저/식당의 초기 탐지 불안정

【원인】 신규 노드는 이웃 엣지가 없어 GNN 메시지 패싱이 불가능하다. 본 데이터셋 기준 Test 노드의 0.2%(13 개)가 이 Cold Start 상태였다.

방식	Test PR-AUC	Test Macro-F1	비고
GNN 단독	0.9359	0.9368	기준
MLP 단독	0.2438	0.2708	피쳐만으로는 역부족
하이브리드 (degree=0 $\rightarrow$ MLP)	0.9367	0.9376	$\Delta+0.0008$ 개선

【향후 방향】 Meta-Learnin 기반 접근(MAML 등)을 도입하면 소수의 이웃만으로도 빠르게 적응하는 few-shot 탐지가 가능하다.

6-4. 정적 그래프 — 장기 시계열 패턴 미반영

【원인】 학습 완료 후 그래프 구조가 고정된다. 수개월에 걸쳐 점진적으로 진화하는 캠페인 패턴을 추론 시점에서 반영할 수 없다.

【향후 방향】 PyTorch Geometric Temporal 의 TGN 으로 전환하면 노드별 메모리 상태를 시간에 따라 갱신하여 장기 패턴을 추적할 수 있다. 이는 아키텍처 전면 교체를 의미하며 중기 로드맵으로 분류하여 진행할 예정이다.

6-5. 영어 데이터 한정 — 한국어 직접 적용 불가

【원인】 SBERT 'all-MiniLM-L6-v2'는 영어 특화 모델로 한국어 리뷰에 직접 적용이 불가능하다.

비교 항목	영어 SBERT (all-MiniLM)	한국어 KoSBERT
임베딩 차원	384d	768d
스팸↔스팸 유사도	—	0.846 ± 0.086
정상↔정상 유사도	—	0.473 ± 0.185
차이 (스팸 신호)	—	+0.373 (R-Sim-R 선별력 유효)
threshold=0.85 옯지 형성률	—	스팸↔스팸 38% / 정상↔정상 0%

아키텍처 변경은 모델명 1 줄 교체와 입력 차원 조정(nn.Linear(386→770))만으로 충분하며, 국내 플랫폼(배달의민족, 카카오맵 등)에 즉시 적용 가능한 확장 방향이다.

8. 추가 참고 자료

- [1] Lee et al. "Temporal Graph Networks for Financial Fraud Detection." AAAI 2024.
- [2] Xu et al. "Inductive Representation Learning on Temporal Graphs." ICLR 2020. (TGAT)
- [3] Tang et al. "Rethinking Graph Neural Networks for Anomaly Detection." ICML 2022. (BWGNN)
- [4] Tang et al. "Dynamic Relation-Attentive Graph Neural Networks for Fraud Detection." ICDMW 2023. (DRAG)
- [5] Dou et al. "Enhancing Graph Neural Network-based Fraud Detection via Locally Homophilous Cluster." CIKM 2020.
- [6] Liu et al. "Pick and Choose: A GNN-based Imbalanced Learning Approach for Fraud Detection." WWW 2021.
- [7] Reimers & Gurevych. "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks." EMNLP 2019.
- [8] Hamilton et al. "Inductive Representation Learning on Large Graphs." NeurIPS 2017.
- [9] Fey & Lenssen. "Fast Graph Representation Learning with PyTorch Geometric." ICLR Workshop 2019.